


PYTHON

1. Библиотеки (пакеты модулей) для научно-инженерных расчетов



NumPy
Base N-dimensional
array package



SciPy library
Fundamental library
for scientific
computing



Matplotlib
Comprehensive 2D
Plotting

IP[y]:
IPython

IPython
Enhanced
Interactive Console



Sympy
Symbolic
mathematics



pandas
Data structures &
analysis

Pythonic DS:

- `numpy` — большие многомерные массивы и матрицы;
- `pandas` — манипуляции с табличными данными (сохранение, загрузка, обработка) («panel data»);
- `sympy` — библиотека **символьных** вычислений.
- `scipy` — библиотека модулей для математической оптимизации, интегрирования, специальных функций, обработки сигналов, обработки изображений, генетических алгоритмов, решения ОДУ и т.д.; `scipy.stats` включает некоторые статистические функции.
- `statsmodels` — статистические модели и тесты;
- `matplotlib` — 2D-визуализация, построение графиков;
- `seaborn` — визуализация (использует `matplotlib`);
- `Bokeh` — визуализация данных для веб-приложений;
- `NetworkX` — построение и визуализация графов;
- `PySpark` — интерфейс для Spark, фреймворк для распределенной обработки неструктурированных и слабоструктурированных данных, входящий в экосистему проектов Hadoop;

ML/DL:

- **Scikit-learn** — библиотека для машинного обучения;
- **Theano** — это расширение языка Python, позволяющее эффективно вычислять математические выражения, содержащие многомерные массивы, с использованием CPU и GPU;
- **TensorFlow** — библиотека для глубинного обучения от Google;
- **Keras** — надстройка над Theano/TensorFlow, которая позволяет на более высоком уровне работать с нейросетями.
- **PyTorch** — интерфейс на Python к библиотеке для глубинного обучения Torch;
- **NLTK** — пакет библиотек и программ для символьной и статистической обработки естественного языка.
- **Gensim** — инструмент для автоматической обработки языка, основанный на машинном обучении.
- **XGboost** (Extreme Gradient Boosting) — библиотека машинного обучения, реализующая модель градиентного бустинга (на основе деревьев решений).

Распределенные вычисления:

- **PySpark** — интерфейс к Apache Spark, фреймворку для распределенной обработки неструктурированных и слабоструктурированных данных, входящий в экосистему проектов Hadoop;

2. NUMPY

NumPy (Numerical Python) — пакет для высокопроизводительных вычислений над большими многомерными массивами (класс `ndarray`), в частности для работы с матрицами (класс `matrix`).

```
sudo pip3 install numpy
```

Основные классы:

- `ndarray` — многомерный массив; создаются с помощью функции `np.array`;
- `matrix(numpy.ndarray)` — матрицы; создаются с помощью `np.matrix`, `np.mat` или `asmatrix`;

Подпакеты Numpy:

- `numpy.random` — содержит ряд функций для генерации случайных чисел, например, `random()`, `rand()`, `randn()`, `randint()` и др.
- `numpy.matlib` — содержит функции для работы с матрицами.

2.1. Класс `ndarray`.

Пример создания массивов **NumPy** (объекта класса `ndarray`):

```
1 import numpy as np
2 a = np.array([1, 2, 3])
3 b = np.array([[1.5, 2, 3], [4, 5, 6]])
4 c = np.array([[1.5, 2, 3], [4, 5, 6]], dtype=np.complex)
```

`array()` — функция, создающая объект типа `ndarray` — преобразует различного вида последовательности в многомерные массивы.

По умолчанию тип данных `int32/float64`. Можно задать/получить с помощью `dtype`.

Атрибуты объектов `ndarray`:

- `ndim` — число осей (измерений) массива;
- `shape` — размеры массива, его форма;
- `size` — число всех элементов массива;
- `dtype` — объект, описывающий тип элементов массива;
- `itemsize` — размер каждого элемента массива в байтах;
- `data` — буфер, содержащий фактические элементы массива;

Функции модуля `numpy` для создания массивов `ndarray`:

- `np.array()` — конвертирует коллекцию/последовательность в массив `ndarray`;
- `np.asarray()` — конвертирует без копирования (если на входе `ndarray`);
- `np.arange()` — для создания массива как последовательности чисел (аналогично `range`);
- `np.eye(n)`, `identity(n)` — единичная матрица (двумерный массив);
- `np.empty()` — массив без заполнения;
- `np.zeros((nx, ny))` — создает массив из нулей,
- `np.ones((nx, ny, nz))` — массив из единиц,
- `zeros_like`, `ones_like`, `empty_like` — создания массива той же формы и типа данных.

```
1 >>> np.arange(10, 30, 5)
2 array([10, 15, 20, 25])
```

2.2. Модуль random.

```
1 import numpy.random as random
2 deviation = 0.2
3 random.normal(size=10**3, scale=deviation)
```

- `random.seed([X], version=2)` — инициализация генератора случайных чисел;
- `permutation` — случайная перестановка;
- `randint(5, size=10)` — посл-ть целых чисел;
- `rand(d0,d1,...)` — равномерное распределение $[0,1)$;
- `rand(d0,d1,...)` — нормальное распределение ($M[X] = 0, \sigma = 1$);
- `normal(loc=0.0, scale=1.0, size=None)` — нормальное распределение ($M[X] = \text{loc}, \sigma = \text{scale}$);
- `uniform(low=0.0, high=1.0, size=None)` — равномерное распределение;

2.3. Типы данных.

```
1 arr = np.array([-2, 0, -3], dtype=np.float64)
```

ТАБЛИЦА 1. Типы данных NumPy

Типы данных	Код	Коммент
int8, uint8	i1, u1	1-байтный целый
int16, uint16	i2, u2	
int32, uint32	i4, u4	
int64, uint64	i8, u8	
float16	f2	
float32	f4 or f	
float64 / float128	f8 or d	Python float
float128	f16 or g	для 64-битных систем
complex64 / 128 / 256	c8, c16, c32	комплексные числа
bool	?	True, False
object	0	Python object type
string_	S	1 байт на символ, напр., S10
unicode	U	платформеннозависим, напр., U10


```
1 arr = np.array([-2, 0], dtype=np.float64)
2 arr = np.array([-2, 0], dtype=float)
3 arr = np.array([-2, 0], dtype='d')
4 arr = np.array([-2, 0], 'f8')
```

```
1 np.array(['python', 'numpy'], dtype='S6')
```

Метод `astype` — конвертация типа данных:

```
1 a = np.array([-2.2, 0.1])
2 b = a.astype(np.int32)
```

2.4. Вычисления. Поэлементные операции:

```
1 arr3 = arr1 * arr2
2 arr4 = arr1 + arr3
```

Broadcasting (распространение):

```
1 arr2 = arr * 5
2 arr2 = 5 * arr
3 arr *= 5
```


Индексация.

```
1 x = arr[1, 3]
2 x = arr[1][3]
```

		axis 1		
		0	1	2
axis 0	0	0,0	0,1	0,2
	1	1,0	1,1	1,2
	2	2,0	2,1	2,2

Срезы (*slicing*).

```
1 s = arr[8:10]
2 arr[3:6] = 5
3 arr[3:6] = [0,0,0]
4 s[:] = -1
```




arr[:2, 1:] (2, 2)




arr[2] (3,)

arr[2, :] (3,)

arr[2:, :] (1, 3)



arr[:, :2] (3, 2)



arr[1, :2] (2,)

arr[1:2, :2] (1, 2)

Условная логика и булева индексация.

```
1 arr == 5
2 arr[arr == 5]
3 arr[(arr >= 5) & (arr <= 8)]
```

`numpy.where(cond, xarr, yarr)` — векторизованная версия `x if cond else y`

```
1 np.where(arr >= 5, arr1, arr2)
2 np.where(arr >= 5, arr, -1)
3 np.where(arr >= 5, 1, -1)
4 np.where((arr >= 5) & (arr <= 8), 1, -1)
```

Методы/функции `any()`, `all()`.

Статистика. `sum`, `mean`, `std`, `var`, `min`, `max`, `argmin`, `argmax`, `cumsum`, `cumprod`

Суммирование:

```
1 arr.sum()
2 np.sum(arr)  # или sum(arr)
```

Среднее значение:

```
1 arr.mean()
2 arr.mean(axis=1)
```

Универсальные поэлементные функции. С одним аргументом (1 массив):

- `abs`, `sign`, `sqrt`, `square`
- `ceil`, `floor`
- `exp`, `log`, `log2`, `log10`, `cos`, `sin`, `tan`, `arccos`, ...

```
1 np.sin(arr)
```

С двумя аргументами (2 массива):

- `add`, `subtract`, `multiply`, `divide`
- `maximum`, `minimum`

```
1 np.maximum(arr1, arr2)
```

Сортировка.

```
1 arr.sort()
2 arr.sort(kind='quicksort') # mergesort, heapsort
```

Kind	Speed	Stable	Work space	Worst-case
'quicksort'	1	No	0	$O(n^2)$
'mergesort'	2	Yes	$n/2$	$O(n \log n)$
'heapsort'	3	No	0	$O(n \log n)$

2.5. Reshape.

```
1 arr = np.array([1, 2, 3, 4])
2 arr = arr.reshape(2, 2)
```

`ravel()`, `flatten()` — выравнивание в одномерный массив

`concatenate([arr1, arr2], axis=0)` — объединение

2.6. Векторизация функций.

`numpy.vectorize(pyfunc, otypes=None)` — определяет векторизованный вариант функции.

`numpy.frompyfunc(func, nin, nout)` — создание NumPy ufunc.

```
1 a = np.array([[1,2],[3,4]])
2 func = lambda x: math.sin(x)
3 vfunc = np.vectorize(func)
4 vfunc(a)
```

```
1 add = np.frompyfunc(lambda x,y: x+y, 2, 1)
2 add(np.arange(8), np.arange(8))    # dtype=object
```

```
1 add = np.vectorize(lambda x,y: x+y, otypes=[np.float64])
2 add(np.arange(8), np.arange(8))
```

```
1 np.add(arr1, arr2)
```

2.7. Доп. возможности. Функции all, any:

```
1 any(x < 5 for x in ls)
2 all(type(x) is np.int64 for x in s)
```

Методы all, any:

```
1 (arr[:,3] == 0).any()
2 (arr[:,3] == 0).all()
```

Срезы:

```
1 arr[:, [3,2,1]]
```

Индексация с помощью массивов:

```
1 b = np.array([(1,1), (1,2), (2,2)])
2 arr[b[:,0], b[:,1]] = -1
```


2.8. **Упражнения.** 1) Преобразовать массив `np.array([[1, 1],[2, 2]])` в список кортожей `[(1, 1), (2, 2)]`.

2) Удалить строки из массива `numpy`, в которых встречается `NaN`. Например,
`x = np.array([[1,2,3], [4,5,np.nan], [7,8,9], [1,0,1]])`

2.9. **Matrix.** Начнем с рассмотрения матриц. Следующий пример демонстрирует создание матрицы размера 2 на 2 и ее вывода на консоль.

```
1 >>> import numpy as np
2 >>> A = np.matrix([[1,2],[3,4]])
3 >>> print(A)
4 [[1 2]
5  [3 4]]
```

С точки зрения ООП написанное здесь можно понимать следующим образом. Во второй строчке происходит создание экземпляра класса `matrix` (из пакета `numpy`), причем в конструктор класса передаем стандартный “питоновский” список, из которого и формируется “матрица” `A`.

После того, как матрица создана, над ней можно производить различные операции. Например, можно вычислить квадрат этой матрицы:

```
1 >>> B = A**2
2 >>> print(B)
3 [[ 7 10]
4  [15 22]]
```

Заметим, что для новой матрицы B нет необходимости явно вызывать конструктор. Он будет вызван автоматически.

Аналогичным образом можно перемножать, складывать и вычитать матрицы, а также умножать матрицы на числа и т.п. (все эти операции уже перегружены в классе `matrix`).

Для более сложных вычислений над матрицами, например нахождения обратной матрицы, необходимо импортировать модуль `linalg` пакета `numpy`, либо отдельные функции из него. Например,

```
1 >>> from numpy.linalg import inv
2 >>> print(inv(A))    # вычисление обратной матрицы
3 [[-2.    1. ]
4  [ 1.5 -0.5]]
```